Giseli Felix e Victor Torres 39, 5°, Manhã.

Respostas
PARTE 1: Árvore de Decisão
1. Alterar a profundidade (`max_depth`**)**

O que aconteceu com a estrutura visual da árvore?
Em `max_depth=2` ficou compacta (2 níveis). A partir de `max_depth=3`, atingiu a separação completa dos dados e manteve a mesma estrutura visual para as profundidades 4, 5 e 8.

A quantidade de decisões (nós e divisões) aumentou ou diminuiu?
Aumentou de 5 nós (3 folhas) em `max_depth=2` para 7 nós (4 folhas) em `max_depth=3`, estabilizando nas seguintes.

A acurácia do modelo no conjunto de teste mudou? Como?
Sim. Subiu de **85,00%** (`max_depth=2`) para **95,00%** (`max_depth=3`) e estabilizou em 95,00%.

Qual profundidade gerou uma árvore mais complexa? Existe risco de overfitting?
A complexidade máxima ocorreu a partir de `max_depth=3` (7 nós). Sim, valores maiores como 8 trazem alto risco de *overfitting* em conjuntos de dados reais por memorizarem o treino.

2. Modificar as variáveis (Features)

O desempenho do classificador mudou quando foram utilizadas diferentes variáveis? Qual característica isolada possui o maior poder preditivo?
Sim. Com 1 variável (apenas glicose) ou 2 (idade e glicose), a acurácia foi de 85,00%; com as 3 variáveis subiu para 95,00%. A **glicose** possui o maior poder preditivo isolado (**85,00%**, contra 65,00% da idade e 55,00% do IMC).

3. Alterar a divisão dos dados (`train_test_split`**)**
Tabela de Acurácia:
20% teste (80% treino): 95,00%
30% teste (70% treino): 93,33%
40% teste (60% treino): 95,00%
O tamanho da base de teste influenciou o resultado da acurácia? Reduzir o volume de treinamento prejudicou o aprendizado do modelo?
Houve apenas uma leve oscilação pontual (93,33% com 30% de teste) decorrente da base pequena (100 linhas). A redução do treino não prejudicou o modelo, pois as regras de corte da glicose são bem delimitadas.

PARTE 2: K-Means (Agrupamento)

1. Alterar o número de grupos (`n_clusters`)

O que acontece com a distribuição visual quando aumentamos o número de grupos?

O espaço é dividido em regiões menores e mais fragmentadas.

Quantos pacientes aproximados ficam em cada grupo?

$K = 2$: ~47 e 53 pacientes.

$K = 3$: ~28, 35 e 37 pacientes.

$K = 4$: ~18, 20, 29 e 33 pacientes.

Os grupos ficam geometricamente maiores ou menores?

Menores.

Como a mudança do gráfico ajuda na interpretação dos perfis dos pacientes?

Permite identificar subgrupos intermediários de risco (ex.: pacientes com glicose intermediária e meia-idade), além do simples perfil binário.

2. Alterar as variáveis do K-Means

A formação dos grupos e o formato das fronteiras de agrupamento mudaram quando foram utilizadas diferentes características?

Sim. O K-Means depende de distâncias euclidianas; alterar as variáveis reconfigura o espaço vetorial e forma novos agrupamentos.

PARTE 3: Comparando os Dois Algoritmos

Experimento	**Árvore de Decisão**	**K-Means**
Alteração da quantidade de variáveis	Melhora o ganho de informação e o acerto das previsões (de 85% para 95%).	Redefine o cálculo de distância euclidiana e altera o formato/significado dos grupos.
Alteração dos parâmetros (`max_depth` / `n_clusters`)	Controla a profundidade das regras: evita *underfitting* (baixo) ou *overfitting* (alto).	Força o número exato de grupos (K), fragmentando o espaço em regiões menores conforme K cresce.
Resultado do Modelo	**Supervisionado (Classificação):** Prevê rótulos conhecidos (0 ou 1) via regras *if-else*.	**Não Supervisionado (Agrupamento):** Agrupa dados por proximidade geométrica sem rótulos prévios.